희소보상 및 장기계획 문제를 위한 계층적 강화학습 기반 Pokémon-Playing Agent



부산대학교 정보컴퓨터공학부

홍세민, 조재우

지도교수: 김원석

목차

목차

1. 소개 3

1.1. 연구 배경 3

1.2. 목표 3

2. 문제 정의 및 해결 전략 4

2.1. Long-Horizon Planning의 부재 4

2.2. Reward Shaping의 난해함 4

2.3. Low-Level Action의 한계점 5

2.4. 정적 환경의 한계 5

3. 시스템 아키텍처 6

3.1. 전체 아키텍처 6

3.2. 시뮬레이션 환경 입출력 정의 7

3.3. Meta-Controller 7

3.4. Skill 7

4. 개발환경 8

4.1. 개발환경 및 사용기술 8

4.2. 평가 지표 9

5. 개발 일정 및 역할 분담 9

5.1. 개발 일정 9

5.2. 역할 분담 9

1. 소개

1.1. 연구 배경

[Physical AI 학습 프레임워크의 필요성] 라스베이거스 CES 2025에서 엔비디아는 '피지컬 AI'를 본격적으로 소개하며, AI가 디지털 공간을 넘어 **실제 물리 환경**에서 인식하고 판단하며 행동하는 방향으로 발전하고 있음을 강조하였다. 피지컬 AI는 카메라와 센서로 주변 환경을 인식하고 이를 바탕으로 로봇이나 자율 시스템이 적절한 행동을 수행하도록 만드는 기술이다. 이러한 시스템을 구현하기 위해서는 환경을 이해하고, 목표에 따라 적절한 행동을 선택하며, **장기적인 과제를 단계적으로 수행할 수 있는 의사결정 능력**이 필요하다.

[기존 방식의 문제점] 최근에는 VLA(Vision-Language-Action Model)와 같은 대규모 모델을 활용하여 로봇이 자연어 지시와 시각 정보를 바탕으로 행동을 수행하도록 하는 연구가 활발히 진행되고 있다. 그러나, 이러한 모델은 **학습에 많은 시간과 비용**이 필요하며, 실제 로봇에 적용시 큰 연산량으로 인해 **행동 결정 과정에서 실시간성이 저하**된다. 전통적인 강화학습은 에이전트는 보상을 최대화하는 행동 정책을 학습한다는 점에서 로봇 정책 학습에 적합하다. 하지만, 단순한 강화학습 방식은 **목표가 길고 복잡한 과제에 적용하기 어렵고**, 원하는 행동을 유도하기 위해 **매우 세밀한 보상 설계가 필요**하다는 문제점이 존재한다.

[계층적 강화학습을 통한 문제 극복] 따라서, 대규모 모델처럼 모든 판단을 하나의 거대한 모델에 의존하는 방식과, 단순 강화학습처럼 낮은 수준의 행동을 직접 학습하는 방식 사이에서, 복잡한 **과제를 구조적으로 분해하고, 단계적으로 해결**할 수 있는 중간 수준의 접근이 필요하다.

1.2. 목표

본 프로젝트의 목표는 '포켓몬스터 레드'라는 방대하고 복잡한 시뮬레이션 환경을 자율적으로 돌파하는 계층적 강화 학습 인공지능 에이전트를 개발하는 것이다. 기존의 단일 강화학습 모델의 한계를 극복하기 위해 계층적 강화학습 아키텍처를 도입하여, 에이전트가 Long-Horizon 플랜을 스스로 수행하며 환경을 정복하는 과정을 증명하고자 한다.

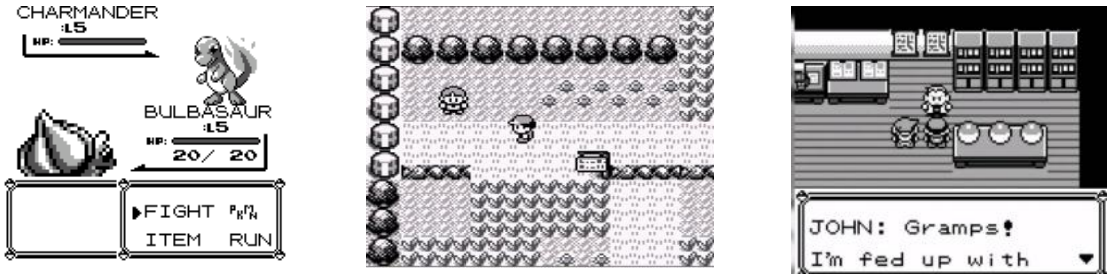


그림 1 복합적인 multi-task로 이뤄진 포켓몬스터 레드 환경

성공적인 계층적 강화학습 프레임워크를 구축을 위해, 에이전트의 행동 구조를 다음과 같이 크게 두 가지 핵심 단위로 나누어 설계한다.

- **1. 특정 task에 특화된 스킬(Skill) 모듈 학습**
- **2. 메타 컨트롤러(Meta-Controller) 구조 설계**
- **3. 스킬-메타 컨트롤러 구조 통합 및 학습**

본 프로젝트는 단일 게임의 클리어를 넘어, 복잡한 순차적 의사결정이 필요한 문제에 범용적으로 적용 가능한 AI 제어 프레임워크를 제시하는 것을 최종 목표로 한다. 본 연구를 통해 검증된 '추상화된 스킬의 모듈화 및 메타-컨트롤러를 통한 계층적 제어'기술은, 향후 다목적 로봇 제어, 자율 주행 등 고도의 상황과 물리적 연속 행동이 요구되는 피지컬 AI를 비롯한 다양한 산업 분야에 효과적으로 이식 및 확장 적용될 수 있을 것으로 기대된다.

2. 문제 정의 및 해결 전략

포켓몬스터 환경은, 전투, 포켓몬스터 획득, 길 찾기, NPC 상호작용 등 여러 task를 순차적으로 수행하고,

2.1. Long-Horizon Planning의 부재

[문제 제기] 단일 에이전트 강화학습의 장기적 목표 학습 어려움

포켓몬스터 레드와 같이 긴 플레이 타임과 복잡한 순차적 이벤트를 가진 환경에서는 단일 강화학습 에이전트가 치명적인 한계를 보인다. 에이전트는 **장기적인 목표를 기억하지 못하고**, 당장 눈앞의 보상만 쫓다가 특정 구간에 무한히 갇히는 **고착상태**에 빠지게 된다.

[해결 방안] 계층적 강화학습 구조 도입

이를 해결하기 위해 전체적인 상태를 조망하고 **장기적인 의사결정을 내리는 상위 RL 에이전트**인 meta-controller(메타 컨트롤러)를 도입한다. 메타 컨트롤러는 직접적인 조작을 하지는 않지만, 거시적인 판단을 내려 장기 플랜의 부재를 해결할 수 있다.

2.2. Reward Shaping의 난해함

[문제 제기] Hard-coding 혹은 Engineering 기반의 보상 설계의 번거로움

기존의 방식과 같이 단일 에이전트 기반 강화학습은 목표에 도달하기 위해 정교한 보상 튜닝이 필요하다. 특히, 포켓몬스터 레드 환경의 매우 긴 스토리를 성공적으로 진행하기 위해, **수백개의 보상을 수동으로 설계**해야 하는 어려움이 존재한다.

[해결 방안] 계층적 보상 구조 분리 및 보상 구조 단순화

보상 구조를 계층적으로 철저히 분리하여, 하위 스킬 에이전트들은 오직 자신에게 주어진 국소적인 역할만 빠르게 학습한다. 반면, 메타 컨트롤러는 체육관 클리어와 같은 굵직한 시나리오 진행에 대해서 보상을 획득한다. 이를 통해 복잡한 보상 설계의 난해함을 해결한다.

2.3. Low-Level Action의 한계점

[문제 제기] low-level action을 통한 복잡한 행동 학습의 어려움 및 학습 망각

하나의 에이전트가 게임보이의 원시적인 조작 버튼 단위로 학습을 진행하면 전투, 탐험, 퍼즐 등의 **복합 행동을 스스로 깨우치기까지 오랜 연산 시간과 시행착오**가 소모된다. 또한, 게임의 학습 단계가 길어질수록 **초반에 학습한 능력을 후반에 잊게 되는 catastrophic forgetting**이 발생한다.

[해결 방안] high-level task 특화 스킬 에이전트 학습

특정 목적에 특화된 독립적인 RL 모델들인 스킬 모듈을 학습시킨 뒤, 메타 컨트롤러를 사용해 **high-level 전문 skill을 사용**한다. A, B 버튼을 누르는 대신 특정 스킬 모듈을 호출하여 다양하고 복잡한 임무 수행을 가능케 한다. 또한 **Skill은 최초 사전학습 이후 Freeze**하여 스킬에 대한 망각을 예방한다.

2.4. 정적 환경의 한계

[문제 제기] 게임 구조가 고정된 환경에서의 학습 다양성 부족

포켓몬스터 레드처럼 맵 레이아웃과 이벤트, 오브젝트 배치가 고정된 게임에서는, **에이전트가 특정 상황에 과적합**되기 쉽다. 이러한 고정 환경만으로는 학습 데이터의 다양성이 부족해 탐색, 정책, 학습 등 skill 학습에 한계가 존재한다.

[해결 방안] ROM 개조를 통한 환경 다양화 및 랜덤화

게임의 **ROM을 개조하여 원하는 환경을 구성하여**, 각 에이전트를 다양한 배치 분포에서 학습을 수행한다. 이로써 특정 상황에서의 과적합을 줄이고, 특정 상황에서의 학습 효율을 극대화할 수 있다.

결론적으로, 본 프로젝트는 포켓몬스터 레드 환경 극복을 위해 **다양성과 랜덤성을 가진 개조된 환경**에서 최소한의 **단순한 보상 구조**로 학습한 각각의 **복잡한 task에 특화된 Skill**을 기반으로 **상위 에이전트인 Meta-Controller가 제어**하는 구조를 제안한다.

3. 시스템 아키텍처

3.1. 전체 아키텍처

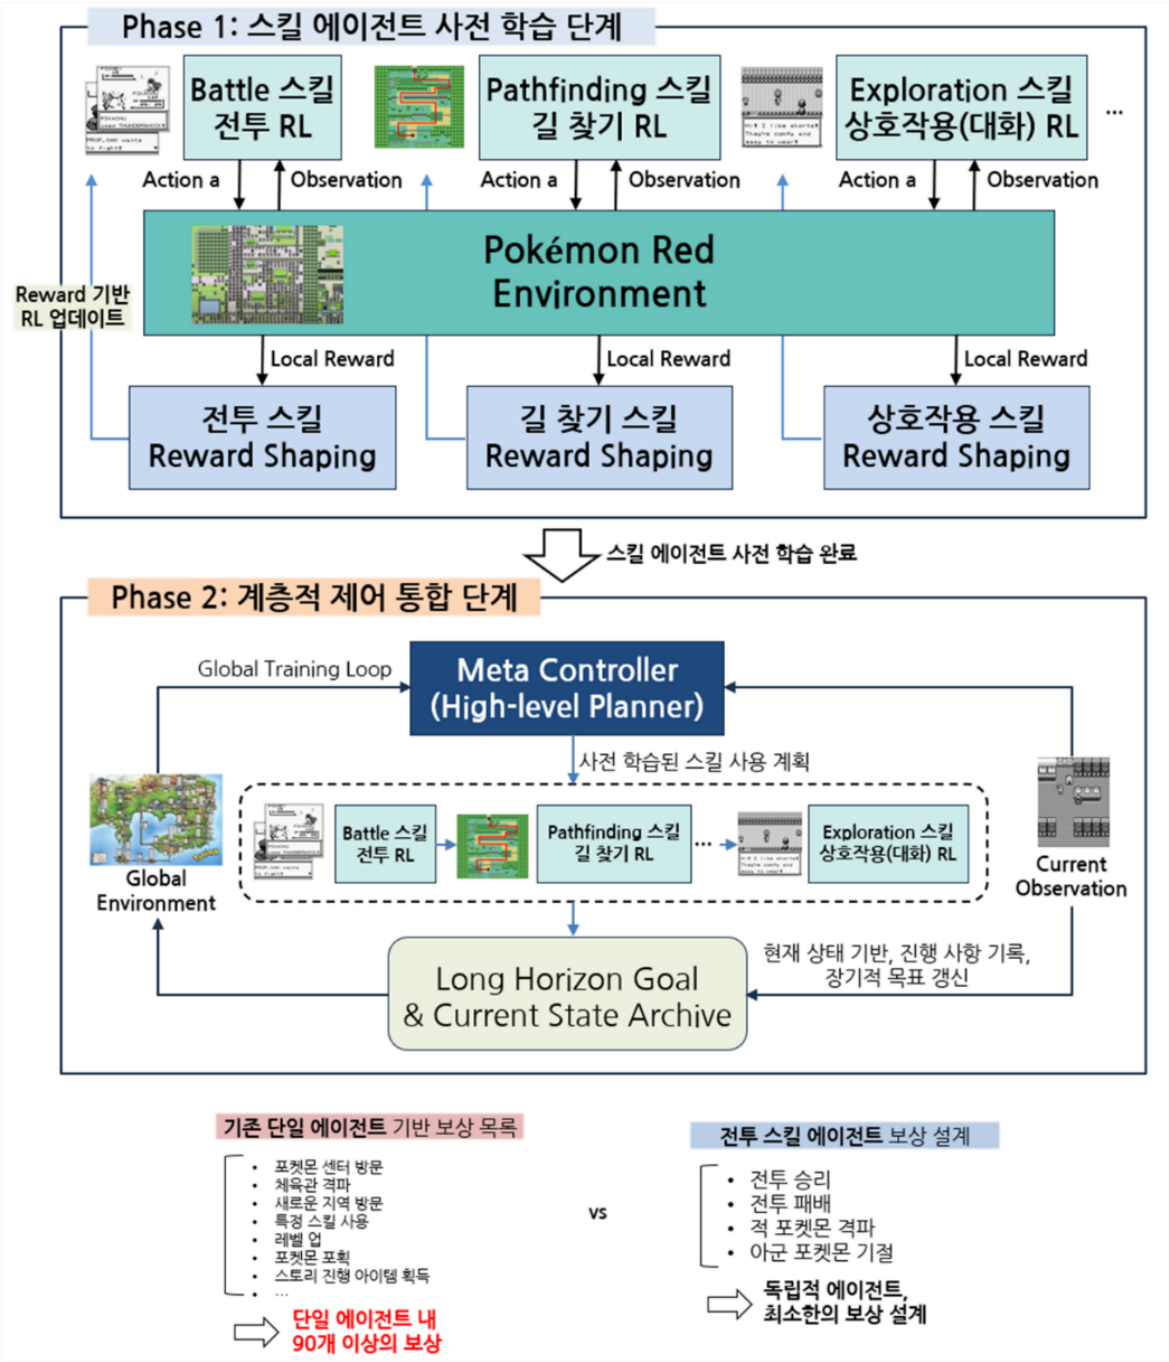


그림 2 포켓몬스터 계층적 강화학습 구조

3.2. 시뮬레이션 환경 입출력 정의

-Meta-Controller

입력: RGB 화면, 이전 실행 Skill의 성공 여부

출력: 다음에 실행할 Skill

-Skill RL

입력: RGB 화면 등

출력: 상하좌우, A, B, Start

3.3. Meta-Controller

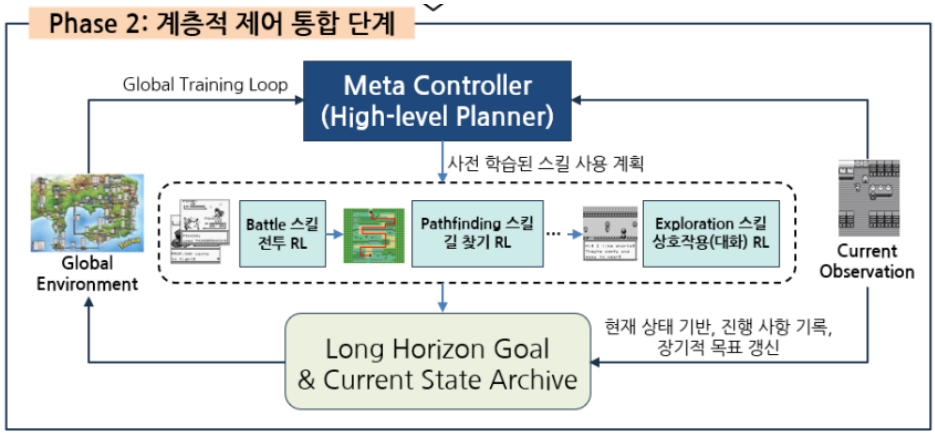


그림 3 Meta-Controller 구조

- 사전 학습된 스킬을 토대로, 매 스텝 적절한 스킬을 선택하는 **고수준 플래너**
- 기억 보존 및 과거 정보를 활용하여 장기 계획 문제를 극복

Meta-Controller는 장기 기억 보존 및 과거의 정보 활용을 위해 다음과 같은 세 가지 모듈로 구성된다.

- **Skill Memory**: 과거의 Skill 성공을 저장하여, 유사한 상황에 활용
- **Skill Selective Policy**: 게임 진행 상황, 화면 등 정보를 토대로 다음 스킬 활성화
- **Skill Outcome Model**: 사용 가능한 스킬에 대한 성공 확률을 출력하여 스킬 선택 보조

3.4. Skill

- 전투 RL

게임 내에서 발생하는 전투 상황에 온전히 특화된 강화학습 에이전트로, 다양한 타입의 적과의 전투 상황을 적절히 판단하여, 불필요한 피해를 최소화하고 효율적인 방식으로 전투를 승리로 이끌도록 행동한다.

- 길 찾기 RL

전체 게임 스토리의 진행 흐름에 따라 에이전트의 현재 위치를 파악하고, 다음 목적지까지의 이동을 전담하는 에이전트로, 복잡한 맵 구조를 극복하여, 목표 지점으로 이동한다.

- 탐험 RL

스토리 전개에 필수적인 환경적 상호작용을 수행하는 에이전트로, 마을 내에 배치된 다양한 NPC들과 대화를 나누며 막힌 이벤트를 활성화하고, 최종적으로 각 지역의 핵심 목표인 포켓몬 체육관장에게 도달하는 탐색 과정을 수행한다.

- 비전머신 RL

게임을 진행하면서 마주치는 특수한 물리적 장애물을 돌파하기 위한 전용 에이전트로, 길을 막는 나무나 물가 같은 특정 상황을 인식하고, 그에 맞춰 '풀베기'나 '파도타기'와 같은 알맞은 기술을 적절하게 선택하여 제어한다.

4. 개발환경

4.1. 개발환경 및 사용기술

구분	항목	상세 내용
개발환경	도구 및 언어	VScode, Cursor / Python
사용기술	에뮬레이터 (Pyboy)	ROM 구동, 입력-프레임-메모리 접근
	RL 환경 표준 (Gymnasium+SB3)	MDP 인터페이스, 정책 학습
	설정 및 수치 (Numpy)	파라미터 외부화 및 게임 화면 배열화
	ROM 개조 (Poke-master)	에이전트 맞춤형 학습 환경 조성

4.2. 평가 지표

1. 주요 이벤트 달성

- 달맞이산 통과, 체육관 관장 격파 등의 게임 주요 스토리 목표 달성 개수

2. 효율성 및 속도 지표

- 각 마일스톤에 도달하는데 소모된 총 타임스텝 수

3. 행동 패턴 및 최적화 지표

- 타일 탐험 개수, 특정 행동 반복 등 무의미한 고착 상태 발생 횟수

5. 개발 일정 및 역할 분담

5.1. 개발 일정

구분	목표	5월	6월	7월	8월	9월	10월
스킬 에이전트 구성 및 학습	각 스킬 에이전트 입출력 정의						
	Reward Shaping 및 스킬 에이전트 학습						
	에이전트 별 역할에 따른 성능 검증						
메타 컨트롤러 학습 및 스킬 통합	메타 컨트롤러 모듈 별 입출력 구조 정의						
	사전 학습된 스킬-메타 컨트롤러 구조 통합 및 학습						
	메타 컨트롤러 성능 검증 및 튜닝						
포켓몬 환경 검증 및 모델 튜닝	평가 지표에 의거한 최종 성능 검증						
	모델 성능 극대화를 위한 하이퍼파라미터 튜닝						

5.2. 역할 분담

이름	담당
홍세민(팀장)	-길 찾기 및 탐험 RL 에이전트 구상 및 학습 -Meta Controller 구상 -하이퍼파라미터 튜닝
조재우	-기술머신 및 전투 RL 구상 및 학습 -Meta Controller 구상